Prediksi Customer Churn Menggunakan Model Machine Leraning

Industri Telekomunikasi

Muhammad Hafizh Hariyanto

4,930	26.7%	F2 = 0.757
Total Customers	Churn Rate	Model Score

Presentation Flow

01

Business Understanding

Problem statement, goals, stakeholder & evaluation metric

02

Exploratory Data Analysis

Data overview, key patterns & churn drivers

03

Modeling

Model selection, algorithm, tuning & performance

04

Conclusion

Summary of findings & business impact

05

Recommendation

Strategic actions to reduce churn rate

Business Understanding

🏢 COMPANY BACKGROUND

ABC Telco menyediakan layanan internet, telepon & digital.

Churn rate industri telko global: 15–25% per tahun
Biaya akuisisi pelanggan baru 5–25× lebih mahal vs retensi.

⚠️ PROBLEM STATEMENT

Churn rate saat ini:

26.7%

Tanpa prediksi → tim hanya bisa reaktif setelah pelanggan sudah pergi.

📌 DEFINISI CHURN

Pelanggan dikategorikan CHURN apabila berhenti menggunakan seluruh layanan ABC Telco — ditandai dengan kolom Churn = "Yes" pada data. Tidak ada definisi berbasis waktu (misal: inaktif X hari) karena data mencerminkan status akhir berlangganan pelanggan.

🤖 KENAPA HARUS ML?

✓ Rule-based terlalu kaku — tidak mampu menangkap interaksi antar banyak fitur sekaligus

✓ Dengan 11 fitur + interaksi kompleks, ML mampu belajar pola non-linear yang tidak terlihat manual

✓ ML memberikan probabilitas per pelanggan → tim bisa prioritas intervensi berdasarkan risk level

📊 APPROACH & METRIC

- Approach: Supervised ML — Binary Classification
- Metric: F2 Score (β=2)
- FN lebih mahal dari FP → bobot Recall 2× lebih besar
- Stakeholder: Tim Retention & Customer Success
- Target: F2 Score ≥ 0.70

Data Understanding

4930
Total Rows

11
Features

77
Duplicates Removed

0
Missing Values

Deskripsi Feature

Feature	Type	Description
tenure	Numeric	Lama berlangganan (bulan)
MonthlyCharges	Numeric	Tagihan bulanan (USD)
Contract	Categorical	Jenis kontrak (M2M/1yr/2yr)
Dependents	Categorical	Memiliki tanggungan (Yes/No)

Feature	Type	Description
InternetService	Categorical	DSL / Fiber optic / No
OnlineSecurity	Categorical	Status layanan keamanan
TechSupport	Categorical	Status dukungan teknis
PaperlessBilling	Categorical	Tagihan digital (Yes/No)
OnlineBackup	Categorical	Status backup online

🎯 **TARGET VARIABLE**

Churn (Yes / No)

Pelanggan yang berhenti berlangganan layanan ABC Telco

Not Churn — 73.3%

Churn — 26.7%

⚠️ Class Imbalance → Perlu resampling

More Than 1 in 4 Customers Are at Risk of Churning

CHURN RATE

26.7%

1,316 customers churned

out of 4,930 total customers

⚠️ Class Imbalance terdeteksi: 73% : 27%
Will be handled using SMOTE during modeling

KEY INSIGHT

Dengan churn rate sebesar 26.7%, perusahaan perlu mengidentifikasi pelanggan berisiko secara proaktif sebelum mereka benar-benar berhenti berlangganan.

$86,961
Revenue at risk per bulan · (1,869 × avg $65.3)

$1.03M
Estimated annual revenue loss · jika churn tidak ditekan

5–25×
Biaya akuisisi pelanggan baru · lebih mahal dari retensi

Month-to-Month Contract Has the Highest Churn Rate (42.7%)

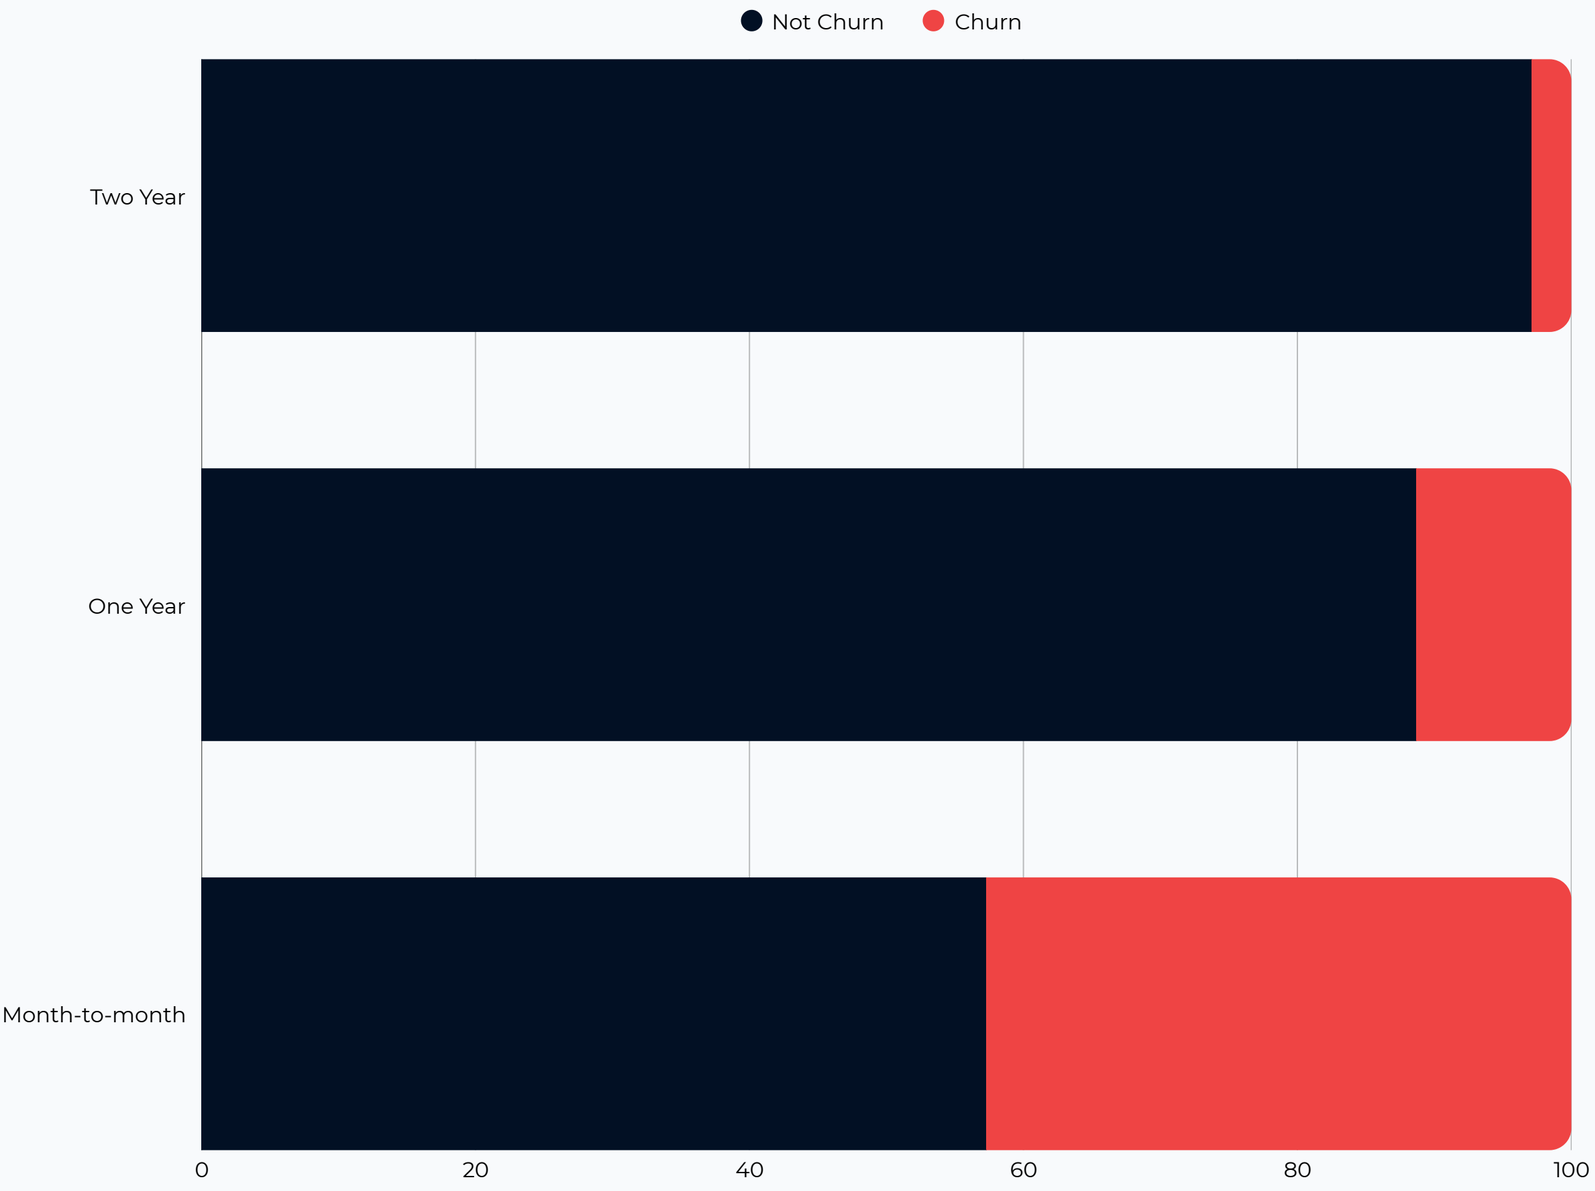

42.7%
Month-to-Month
Churn Rate

11.3%
One Year
Churn Rate

2.9%
Two Year
Churn Rate

💡 Prioritas: Tawarkan upgrade kontrak tahunan kepada pelanggan month-to-month untuk menurunkan churn rate

New Customers & High Charges Are the Most Likely to Churn

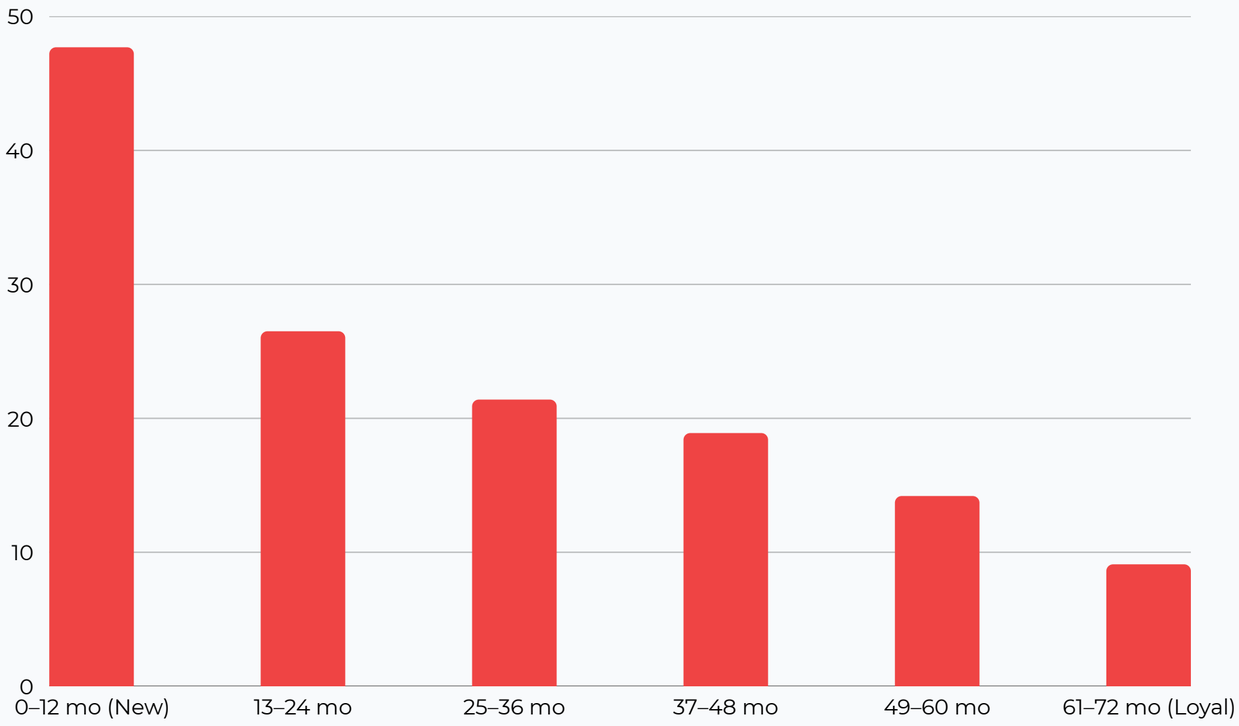

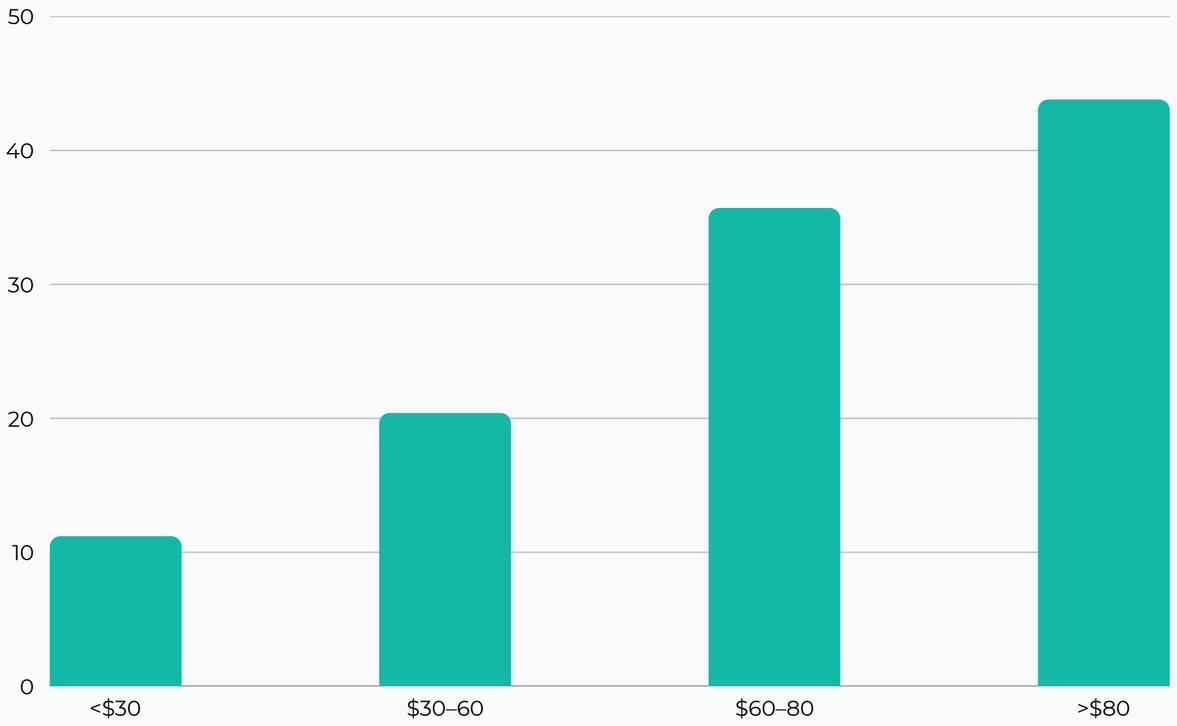

📉 Tenure Effect

Pelanggan baru (0–12 bln) churn rate 47.7% — 5× lebih tinggi dari pelanggan loyal (>60 bln)

💰 Price Sensitivity

Tagihan >$80/bln memiliki churn rate 43.8%, menandakan pelanggan sensitif terhadap harga tinggi

🔗 Korelasi Fitur

Contract: −0.40 | Tenure: −0.36 | MonthlyCharges: +0.19 (korelasi dengan Churn)

Fiber Optic Users & Customers Without Add-On Services Churn More

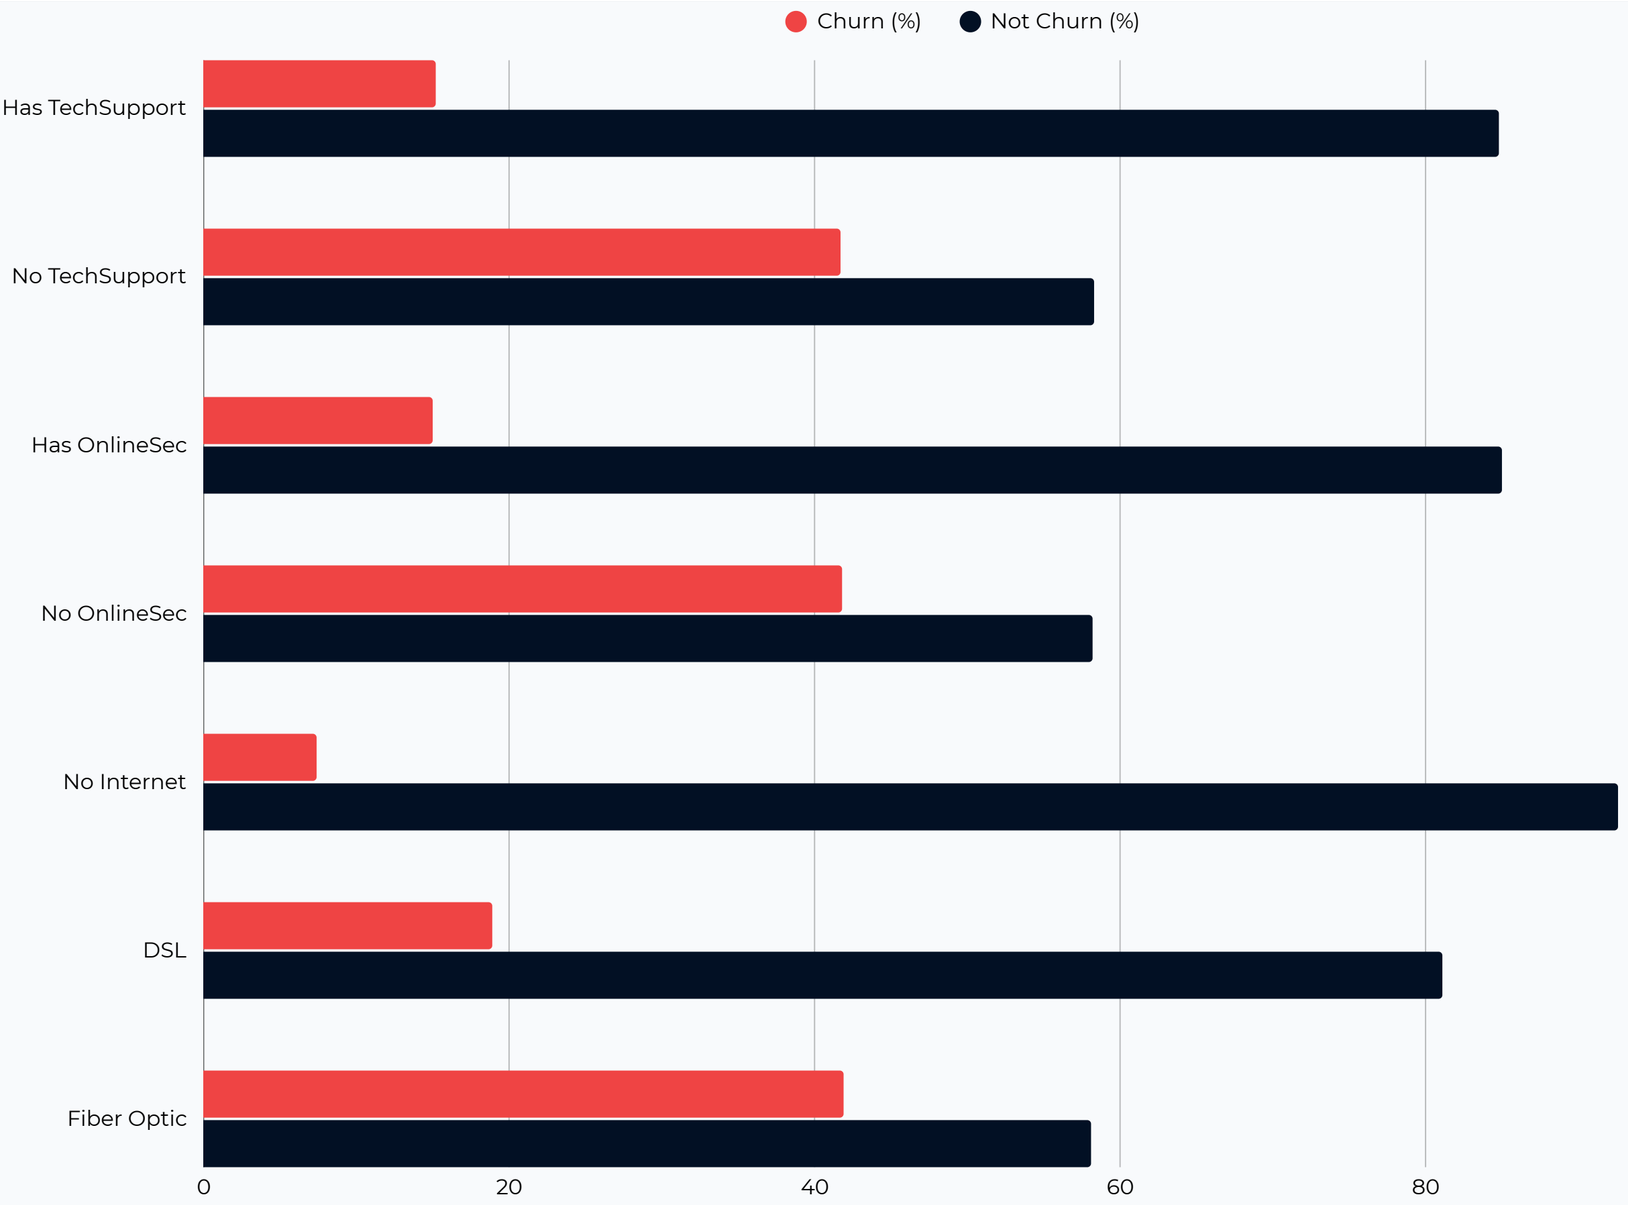

41.9%
Fiber Optic · Churn rate tertinggi di antara jenis internet

41.8%
No Online Security · Pelanggan tanpa security lebih rentan churn

18.9%
DSL · Jauh lebih stabil vs Fiber Optic

15.2%
Has TechSupport · Layanan pendukung meningkatkan retensi

Data Cleaning & Feature Engineering

DATA CLEANING STEPS

1

Remove Duplicates

77 baris duplikat dihapus

2

No Missing Values

Tidak ada missing
→ tidak perlu imputation

3

No Outliers

IQR check: nilai ekstrem
masih wajar secara bisnis

4

Not Normal Dist.

Shapiro-Wilk $p \leq 0.05$
→ Gunakan RobustScaler

FEATURE ENGINEERING

tenure_category

Kategori lama berlangganan
→ New / Medium / Long / Loyal

💡 Capture non-linear tenure effects

total_services

Jumlah layanan tambahan yang aktif
→ 0 sampai 4 layanan

💡 Pelanggan dgn lebih banyak layanan lebih stabil

has_internet

Apakah pelanggan punya
layanan internet (0/1)

💡 Internet service = churn risk indicator

Preprocessing: RobustScaler (numeric skewed) · MinMaxScaler (binary/count) · OneHotEncoder (categorical) · Train/Test Split 80:20 stratified

Data Preparation & Modeling Setup

1 TRAIN-TEST SPLIT (stratify=y)

TRAIN — 80% (3,882 rows)	TEST — 20% (971 rows)

2 RESAMPLING METHODS

None — Baseline

Tidak ada resampling
Model langsung dilatih
dengan data asli (imbalanced)

SMOTE — ✓ Terpilih

Synthetic Minority Over-sampling — buat data sintetis kelas minoritas

Undersampling — Compared

RandomUnderSampler — kurangi kelas mayoritas secara acak

3 FEATURE SELECTION

None (All Features) — ✓ Terpilih

Semua fitur digunakan tanpa seleksi

SelectKBest (k=10) — Tested

Pilih 10 fitur terbaik berbasis f_classif score

SelectKBest (k=15) — Tested

Pilih 15 fitur terbaik berbasis f_classif score

4 MODELS TESTED

Logistic Regression	✓ Final
Decision Tree	Tested
Random Forest	Tested
Boosting (Gradient,XG,Cat)	Tested
Extra Trees	Tested
Bagging	Tested

Total kombinasi yang diuji: 9 models × 3 resampling × 3 feature selection = 81 kombinasi | Semua dievaluasi dengan Cross Validation CV=5 menggunakan F2 Score

Logistic Regression + SMOTE Performs Best Across All Combinations

9	3	3	81
Models Tested	Resampling Methods	Feature Selections	Total Combinations

TOP 5 BENCHMARK RESULTS (F2 Score)

Rank	Model	Resampling	Feature Select	F2 Score	Recall
🥇 1	Logistic Regression	SMOTE	None (All Features)	0.637	0.643
2	Logistic Regression	SMOTE	SelectKBest (k=10)	0.626	0.639
3	Logistic Regression	SMOTE	SelectKbest (k=15)	0.625	0.636
4	Logistic Regression	Undersampling	None	0.6226	0.628
5	Logistic Regression	Undersampling	SelectKBest (k=10)	0.6222	0.628

🔍 Interpretable

Koefisien mudah dijelaskan ke stakeholder bisnis

⚡ Efficient

Training cepat, tidak perlu komputasi berat

✅ Generalizes Well

F2 Train vs Test sangat berdekatan — tidak overfit

How Logistic Regression Works

THE ALGORITHM

Logistic Regression memprediksi probabilitas sebuah event (churn/tidak) menggunakan fungsi sigmoid yang menghasilkan nilai antara 0 dan 1.

Odds Ratio

$$\text{Odds} = p / (1 - p)$$

Log-Odds (Logit)

$$\text{logit}(p) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots$$

Sigmoid Function

$$p = 1 / (1 + e^{-z})$$

Jika $p \geq$ threshold → Churn = 1, jika $p <$ threshold → Churn = 0

DECISION PROCESS

1. **Input Features**
   tenure, Contract, MonthlyCharges, dll.
2. **Calculate Log-Odds**
   Kalikan setiap fitur dengan koefisien β
3. **Apply Sigmoid**
   Konversi ke probabilitas 0–1
4. **Apply Threshold**
   0.25 → prediksi Churn jika $p \geq 0.25$

✅ **Koefisien dapat diinterpretasikan langsung sebagai pengaruh tiap fitur terhadap probabilitas churn**

Threshold 0.25 Delivers the Best F2 Score — Catching 88.8% of Churners

GRIDSEACHCV BEST HYPERPARAMETERS

C (Regularization) **10**	Keseimbangan fit vs regularization
Penalty **L1**	Mencegah overfitting
Solver **saga**	Optimal untuk dataset kecil-menengah
SMOTE Strategy **0.5**	Synthetic minority oversampling

BEFORE vs AFTER TUNING

	Before Tuning	After Tuning
F2 Score (Train)	0.6287	0.6329
F2 Score (Test)	0.6370	**0.6403** ▲

THRESHOLD OPTIMIZATION

Default Threshold

0.50

F2: 0.640 | Recall: 64.7%

Optimal Threshold ★

0.25

F2: 0.757 | Recall: 88.8%

Final Model Detects 88.8% of Churning Customers (F2 = 0.757)

F2 Score

0.757

Target ≥ 0.70 ✅

Recall

88.8%

229 of 258 churners caught

Precision

47.6%

Of predicted churn, 48% actual

ROC-AUC

0.845

Strong discriminative ability

CONFUSION MATRIX (THRESHOLD 0.25)

	Predicted: Not Churn	Predicted: Churn
Actual: Not Churn	**TN = 461**	FP = 252
Actual: Churn	**FN = 29 (MOST COSTLY)**	**TP = 229**

TP = 229

Churn berhasil dideteksi

TN = 461

Tidak churn, benar diprediksi

FP = 252

Tidak churn tapi diprediksi churn
→ biaya retensi tidak perlu

FN = 29

Churn tidak terdeteksi
→ PALING MAHAL untuk bisnis

PR-AUC: 0.647 | Tidak overfit: F2 Train (0.633) ≈ F2 Test (0.640) sebelum threshold opt | **Setelah threshold 0.25: F2 = 0.757** ✅

Tenure & Contract Type Are the Strongest Predictors of Churn

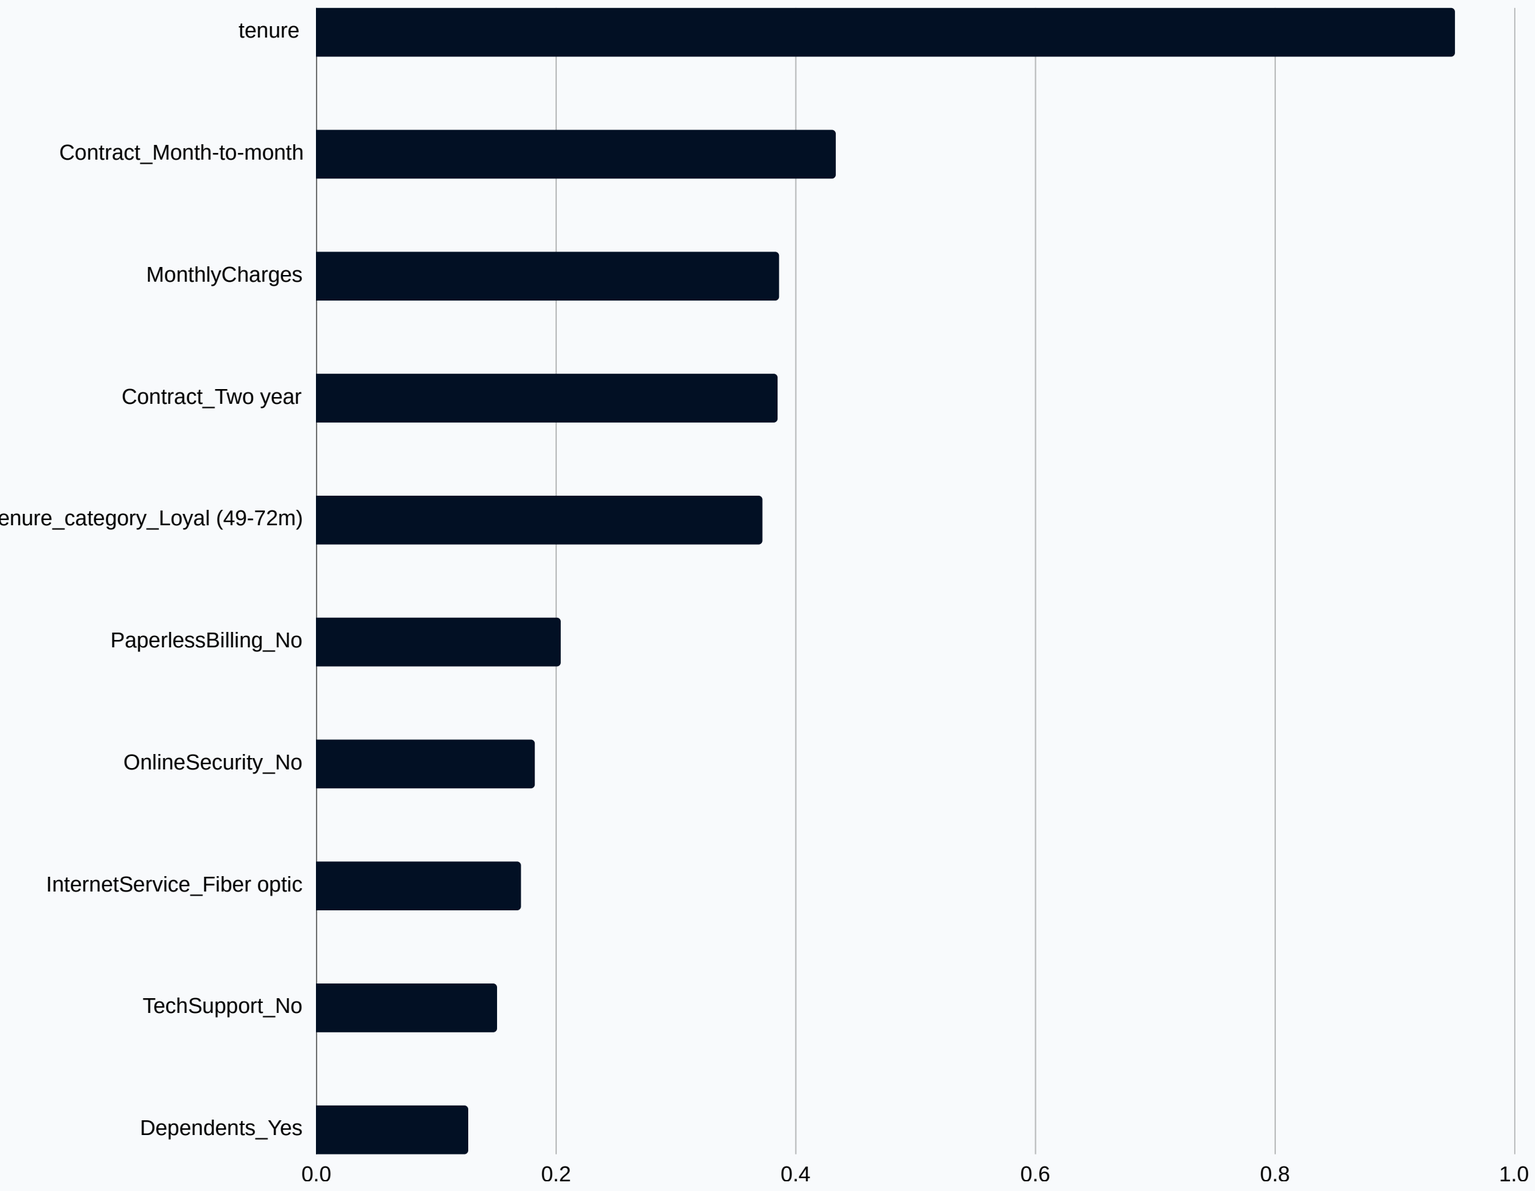

#01

tenure

Lama berlangganan adalah prediktor terkuat. Pelanggan baru sangat berisiko churn.

#02

Contract_Month-to-month

Kontrak bulanan meningkatkan risiko churn signifikan — tidak ada komitmen jangka panjang.

#03

MonthlyCharges

Tagihan tinggi membuat pelanggan lebih sensitif terhadap harga.

#04

Contract_Two year

Kontrak 2 tahun menurunkan risiko churn — efek retensi kuat.

Model Limitations & Improvement Opportunities

📅 Data Scope

- Dilatih dari data historis — tidak menangkap perubahan perilaku pelanggan terbaru
- Performa bisa menurun jika ada perubahan besar pada paket atau struktur harga

📊 Performance Range

- Terbaik untuk pelanggan tenure 0–12 bulan (data paling banyak & churn rate tinggi)
- Performa menurun pada pelanggan loyal (tenure > 48 bln) karena sampel minoritas

🔄 Maintenance

- Model harus di-retrain setiap 3–6 bulan dengan data terbaru
- Pantau model drift: jika F2 Score produksi turun < 0.70 → segera retrain

➕ Missing Features

- Customer complaint history belum masuk model
- Frekuensi penggunaan layanan (usage data) dan NPS bisa meningkatkan performa

🚀 Better Alternatives

- Ensemble methods (XGBoost, LightGBM) bisa meningkatkan Precision
- Threshold dinamis per segmen pelanggan dapat meningkatkan efisiensi bisnis

🔍 Validation

- Perlu A/B testing untuk validasi efektivitas program retensi vs metode konvensional
- SHAP values perlu dikomunikasikan ke tim bisnis secara rutin

Machine Learning Saves $5,142 (9.7%) Compared to Rule-Based Approach

COST ASSUMPTIONS : False Positive (FP) = $100/customer (biaya retensi: call + voucher) | False Negative (FN) = $783.86/customer (CLV: avg $65.32/bln × 12 bln)

WITHOUT ML (Rule-Based)

	Pred: Not Churn	Pred: Churn
Actual: Not Churn	TN = 292	**FP = 421**
Actual: Churn	FN = 14	**TP = 244**

Total Cost:

$53,074

(421 FP × $100) + (14 FN × $784)

WITH ML (Our Model) ⭐

	Pred: Not Churn	Pred: Churn
Actual: Not Churn	**TN = 461**	FP = 252
Actual: Churn	**FN = 29**	**TP = 229**

Total Cost:

$47,932

(252 FP × $100) + (29 FN × $784)

💰 **Machine Learning menghemat $5,142 (9.7% lebih efisien) dibanding Rule-Based, dengan target pelanggan yang jauh lebih akurat**

Conclusion

01

Model Target Tercapai

Logistic Regression + SMOTE + Threshold 0.25 menghasilkan F2 Score 0.757 — melampaui target ≥ 0.70 — dengan Recall 88.8%

02

ML Lebih Unggul dari Rule-Based

Meskipun Recall Rule-Based sedikit lebih tinggi (94.6% vs 88.8%), ML 9.7% lebih hemat secara total biaya bisnis karena FP jauh lebih rendah

03

Faktor Utama Churn Teridentifikasi

Kontrak bulanan (43% churn rate), tenure pendek (< 12 bln), Fiber Optic, dan tidak adanya layanan tambahan menjadi driver utama churn

04

Model Siap Deployment

Model tersimpan dalam format .pkl, siap di-deploy via Streamlit untuk prediksi real-time oleh tim Customer Success

Recommendation

CUSTOMER RETENTION STRATEGY BY RISK LEVEL

HIGH RISK — Prob > 75%

Telepon langsung + tawarkan kontrak tahunan diskon 20–30%

⏱ **Respons dalam 24 jam**

MEDIUM RISK — Prob 50–75%

Email personal + free trial OnlineSecurity / TechSupport 1 bulan

⏱ **Respons dalam 3 hari**

LOW RISK — Prob < 50%

Masukkan ke program loyalty reguler — tidak perlu intervensi intensif

⏱ **Monthly campaign**

SPECIFIC BUSINESS ACTIONS

📋 Konversi Kontrak

Insentif upgrade ke kontrak 1–2 tahun (diskon, bundling, hadiah loyalitas) untuk pelanggan M2M berisiko

🎓 Onboarding Intensif

Program welcome terstruktur untuk tenure < 6 bln: check-in mingguan + loyalty reward di bulan ke-3

📦 Bundling Layanan

Dorong aktivasi min. 3 layanan tambahan — pelanggan dengan lebih banyak layanan terbukti lebih stabil

📊 Dashboard Monitoring

Jalankan model tiap bulan + churn risk dashboard real-time untuk tim Customer Success

🎯 KPI Target: Kurangi churn rate dari 26.7% menjadi ≤ 20% dalam 6 bulan pertama implementasi

Referensi: *Gallo, A. (2014). The Value of Keeping the Right Customers. Harvard Business Review. | Userpilot. (2024). Average Customer Acquisition Cost: Benchmarks by Industry. | Reichheld, F. (2001). Loyalty Rules. Harvard Business School Press.*

Thank You

Muhammad Hafizh Hariyanto
Data Scientist

0.757	88.8%	$5,142
F2 Score	Recall	Cost Saved

Aplikasi Churn Prediction Telco